



*Facultad
de
Ciencias*

**GESTIÓN CENTRALIZADA DE LOGS PARA
SERVICIOS BIG DATA DESPLEGADOS
SOBRE UNA ARQUITECTURA CENTRADA
EN EL DATO**

**CENTRALIZED LOG MANAGEMENT FOR BIG
DATA SERVICES DEPLOYED ON A DATA-
CENTRIC ARCHITECTURE**

Trabajo de Fin de Grado
para acceder al

GRADO EN INGENIERÍA INFORMÁTICA

Autor: Jesús Saiz Gutiérrez

Directora: Marta Zorrilla Pantaleón

Junio - 2024

Agradecimientos

Primero me gustaría dar las gracias a mi familia por darme la posibilidad de estudiar lo que quería, algo que no cualquiera puede decir, y por el apoyo brindado durante los últimos 4 años.

Finalmente, también tengo que agradecerle a mi tutora Marta Zorrilla Pantaleón por guiarme y ayudarme durante el desarrollo del proyecto.

Resumen

En el ámbito empresarial actual, se utilizan numerosas aplicaciones y servicios que necesitan funcionar de manera eficaz. Cada uno de estos componentes produce datos propios sobre su rendimiento. Sin embargo, la gestión de esta información a menudo no es óptima debido a la gran cantidad de servicios y datos generados.

Este proyecto busca desarrollar un sistema de gestión de registros sobre una plataforma big data distribuida y escalable que incluye el uso de Kafka como gestor de eventos, entre otras tecnologías.

Más específicamente, el objetivo es implementar un sistema de gestión de registros utilizando el conjunto de herramientas ELK (Logstash, Elasticsearch y Kibana) para recopilar, procesar y visualizar el estado de los diversos servicios de la plataforma big data.

Palabras clave

Registros de eventos, Monitorización, Cuadro de mandos, Big Data, Stack ELK

Abstract

In today's business environments, a vast array of applications and services is utilized, each of which must operate correctly. Each of these components generates its own information about its status. However, due to the high number of services and the volume of information produced, this information is often not adequately monitored.

This project aims to create a log management system on a scalable and distributed big data platform utilizing the Kafka event manager among other technologies.

More specifically, it seeks to implement a log management system using the ELK stack (Logstash, Elasticsearch, and Kibana) to collect, process, and visually display the status of various services within the big data platform.

Keywords

Logs, Monitoring, Dashboard, Big Data, ELK Stack

Índice

Índice	5
1. Introducción	9
1.1. Importancia de la gestión de logs	9
1.2. Objetivo	9
1.3. Arquitectura y caso de uso	10
1.4. Elección de tecnologías para la gestión y análisis de logs	10
1.5. Organización de la memoria	11
2. Stack ELK	11
2.1. Logstash	12
2.2. Elasticsearch	13
2.3. Kibana	14
2.4. Filebeat	14
3. Despliegue de la plataforma big data y del Stack ELK en entorno local	14
3.1. Configuración del fichero .yaml de despliegue	15
3.2. Configuración de logs de Kafka	20
3.2.1. Ficheros de logs de Kafka	20
3.2.2. Autenticación vs Autorización en Kafka	21
3.2.3. Configuración de la autenticación/autorización de acceso de Kafka	21
4. Diseño de la solución en entorno local	23
4.1. Configuración del Stack ELK	24
4.1.1. Filebeat	25
4.1.2. Logstash	26
4.1.3. Elasticsearch	32
4.2. Cuadro de mandos - Kibana	33
4.2.1. Observabilidad	33
4.2.2. Análisis	34
4.2.3. Dashboard y Lens	34
4.3. Limitaciones de la solución local	38
4.3.1. Explicación del problema de almacenamiento	39
5. Diseño de la solución en la nube	40
5.1. Docker	40
5.2. Kubernetes	43
5.2.1. Zookeeper	43
5.2.2. Elasticsearch	43

5.2.3.	Kibana	44
5.2.4.	Filebeat	46
6.	Conclusiones y líneas de trabajo futuras	47
7.	Bibliografía.....	48

Índice de imágenes

Imagen 1: Arquitectura general del sistema.....	12
Imagen 2: Formato de logs proporcionado por Logstash por defecto.....	13
Imagen 3: Formato de logging de 5 ficheros de Kafka.....	30
Imagen 4: Formato de logging de 1 fichero de Kafka.....	31
Imagen 5: Visualización de campos en Kibana para los 5 ficheros	32
Imagen 6: Visualización de campos en Kibana para el fichero independiente.....	32
Imagen 7: Índices por defecto de Elasticsearch	33
Imagen 8: Menú principal de Observability de Kibana	34
Imagen 9: Filtrado errores de acceso del usuario2.....	34
Imagen 10: Creación de una visualización con Lens	35
Imagen 11: Dashboard para la autenticación y autorización de Kafka	35
Imagen 12: Número de fallos de autorización por usuario	35
Imagen 13: Número de fallos de autenticación por ip.....	36
Imagen 14: Fallos de autorización por usuario en el dominio del tiempo.....	36
Imagen 15: Fallos de autenticación por ip en el dominio del tiempo.....	37
Imagen 16: Tipos de operaciones de autorización denegadas.....	37
Imagen 17: Tipos de peticiones de autorización denegadas	37
Imagen 18: Tipo de recursos a los que se intenta acceder	38
Imagen 19: Recursos específicos a los que se intenta acceder	38
Imagen 20: Dashboard filtrado por la actividad del usuario usuario1	38
Imagen 21: Menú discover de Kibana desplegado en la nube.....	42
Imagen 22: Nodos por defecto de Kubernetes.....	43

1. Introducción

Este Trabajo de Fin de Grado se ha realizado en el seno del grupo de investigación ISTR, dentro del proyecto nacional “Modelos y plataformas para sistema informáticos industriales predecibles, seguros y confiables”. En particular, en la línea de investigación “Aplicaciones inteligentes de datos para I4.0. Casos de uso”, cuyo fin es diseñar y desplegar aplicaciones de uso intensivo de datos sobre una infraestructura big data escalable y distribuida, bajo una arquitectura Kappa [15] y conforme al metamodelo RAI4.0 [19].

Este metamodelo busca ofrecer una estrategia para el diseño y despliegue de aplicaciones que requieren un uso intensivo de datos en contextos distribuidos que emplean, entre otros, sistemas IoT y servicios desplegados en entornos híbridos.

En este contexto, el TFG partirá de un caso de uso contextualizado en IoT industrial utilizando Kafka como gestor de eventos de la plataforma big data, además de otros servicios que permiten la visualización de datos y supervisión del funcionamiento de la plataforma big data.

1.1. Importancia de la gestión de logs

La gestión de logs en cualquier infraestructura es siempre importante, pero aún más en entornos distribuidos complejos [8], porque permite a los departamentos de IT monitorizar y analizar el comportamiento de sus servicios, y poder plantear estrategias de contingencia.

Los logs actúan como un registro detallado de eventos, errores y transacciones, lo que ayuda a identificar problemas, a entender el funcionamiento del servicio y a detectar posibles brechas de seguridad. Una gestión efectiva de logs facilita la resolución proactiva de incidencias, mejora el rendimiento de los sistemas y asegura el cumplimiento de las normativas de auditoría y seguridad.

En esencia, los logs son una pieza clave para mantener la integridad y la operatividad óptima de los servicios tecnológicos utilizados por la organización.

1.2. Objetivo

Este trabajo de fin de grado tiene por objeto diseñar e implementar un sistema centralizado para gestionar, monitorizar y analizar logs de los distintos servicios desplegados en una arquitectura big data centrada en el dato, utilizando las tecnologías Logstash, Elasticsearch y Kibana, agrupadas bajo el nombre de Stack ELK.

Para su consecución se planificaron las siguientes fases:

- **Desplegar y configurar on-premise la plataforma de servicios big data que será auditada y monitorizada por el sistema.**
- **Definir e implementar un pipeline para el procesamiento de logs:** Esto es, realizar un flujo de datos para la captura, procesamiento y visualización de los logs con Filebeat, Logstash, Elasticsearch [9] y Kibana [13].
- **Determinar y establecer estrategias para el filtrado y procesamiento de logs:** Esto es, diseñar criterios de acuerdo con los requisitos de análisis que se especifiquen para estructurar, filtrar y procesar los logs adecuadamente.
- **Crear cuadros de mando o dashboards:** Esto es, crear interfaces visuales que faciliten y ayuden a la interpretación de los logs y su análisis para la toma de decisiones.
- **Desplegar la solución en la nube:** Lo cual mejorará el almacenamiento y aprovechará las ventajas de escalabilidad, disponibilidad y flexibilidad que los

entornos en la nube ofrecen para manejar grandes volúmenes de datos y registros en tiempo real.

1.3. Arquitectura y caso de uso

El sistema bajo desarrollo se ha de implantar sobre una plataforma digital conforme al metamodelo RAI4.0 [13]. Esto es un sistema distribuido y escalable soportado sobre un bus de datos en el que están desplegados distintos servicios. Las tecnologías que dan soporte a estos servicios son las que deben ser monitorizadas.

Estas tecnologías son:

- **Apache Kafka:** Gestor de eventos en tiempo real que facilita la recolección, el procesamiento y el almacenamiento de flujos de datos continuos. Utiliza un sistema de intercambio de datos que opera bajo el modelo productor-consumidor. Esta tecnología es la que soporta el bus de datos y por ello es el servicio principal bajo supervisión.
- **Zookeeper:** Facilita la coordinación entre procesos distribuidos mediante un espacio de nombres jerárquico común de registros de datos, conocidos como znodes. Es un servicio necesario para el funcionamiento de la plataforma big data.
- **Apache Spark:** Es un framework de programación de propósito general para procesamiento de datos distribuidos a gran escala.
- **Cassandra:** Sistema de gestión de bases de datos NoSQL.

El caso de uso general abordado en este proyecto se centra en la gestión de logs de los servicios desplegados, en particular, de Kafka [11] y el control de seguridad. Se hace énfasis especial en los logs relacionados con la autenticación y autorización. Este enfoque implica la supervisión y el análisis de los eventos de seguridad dentro de la plataforma, lo cual es crucial para garantizar un acceso controlado a los recursos y operaciones. La gestión adecuada de estos logs es esencial para detectar, investigar y mitigar posibles incidentes de seguridad, asegurando la integridad y confidencialidad de los datos gestionados por Kafka.

1.4. Elección de tecnologías para la gestión y análisis de logs

Existe una gran variedad de tecnologías que permiten crear un sistema de gestión de logs, entre ellas se encuentran las siguientes:

- Splunk [1]
- Graylog [2]
- Fluentd [3]
- Prometheus [4] y Grafana
- Loki [5]
- Datadog [6]
- Sumo Logic [7]
- Stack ELK

Se analizaron de forma general todas ellas y se determinó que los parámetros principales a tener en cuenta para su comparación son: la naturaleza open source, la comunidad, el nivel de personalización que permite, la flexibilidad para integrarse con otras herramientas, la escalabilidad y el principal uso de la herramienta.

Herramientas como Splunk, Datadog y Sumo Logic son descartadas debido a que no son de naturaleza open source. Loki es una herramienta que se suele integrar con Grafana y un

recolector de logs como Promtail, Fluentd o Logstash, es decir, es similar al Stack ELK, pero con un uso menos extendido. Graylog es una plataforma completa de gestión de logs que puede funcionar de manera autónoma, con su propio recolector de logs, interfaz de visualización y almacenamiento en MongoDB y Elasticsearch. Sin embargo, al ser una solución de arquitectura predefinida, no permite tanta personalización ni control como creando tu propia plataforma propietaria. Finalmente, Prometheus y Grafana se utilizan principalmente para el monitoreo de métricas en lugar de logs.

Teniendo en cuenta todos estos parámetros, se decidió emplear el Stack ELK para este proyecto. Su naturaleza open source, gran comunidad, extensas capacidades de personalización, alta escalabilidad y la posibilidad de construir una plataforma propietaria lo hacen la opción ideal para la gestión y análisis de logs en este proyecto.

1.5. Organización de la memoria

Después de esta introducción, la memoria se organiza de la siguiente manera. En el capítulo 2 se explora el Stack ELK (Elasticsearch, Logstash, Kibana) y Filebeat, detallando el funcionamiento de cada herramienta. En el capítulo 3 se describe el proceso de despliegue en local usando Docker. Además, se detallan los logs de Kafka, sus formatos y localizaciones, y la configuración de autenticación y autorización en Kafka. En el capítulo 4 se organiza el diseño de la solución global para la gestión de logs, se describe qué logs se monitorizan y para qué objetivos, cómo se organizan en índices en Elasticsearch, y cómo se visualizan en Kibana. En el capítulo 5 se describe la transición a una solución en la nube utilizando Google Cloud, explicando cómo se implementa y se mejora la gestión de logs en un entorno escalable y flexible. Por último, en el capítulo 6 se recogen las conclusiones y líneas de trabajo futuras.

2. Stack ELK

El Stack ELK de código abierto, incluye tres tecnologías principales: Elasticsearch, Logstash y Kibana, además de otras tecnologías secundarias como Filebeat.

Antes de explicar las herramientas, se muestra en la imagen 1 un esquema que describe la comunicación entre ellas para el análisis de logs.

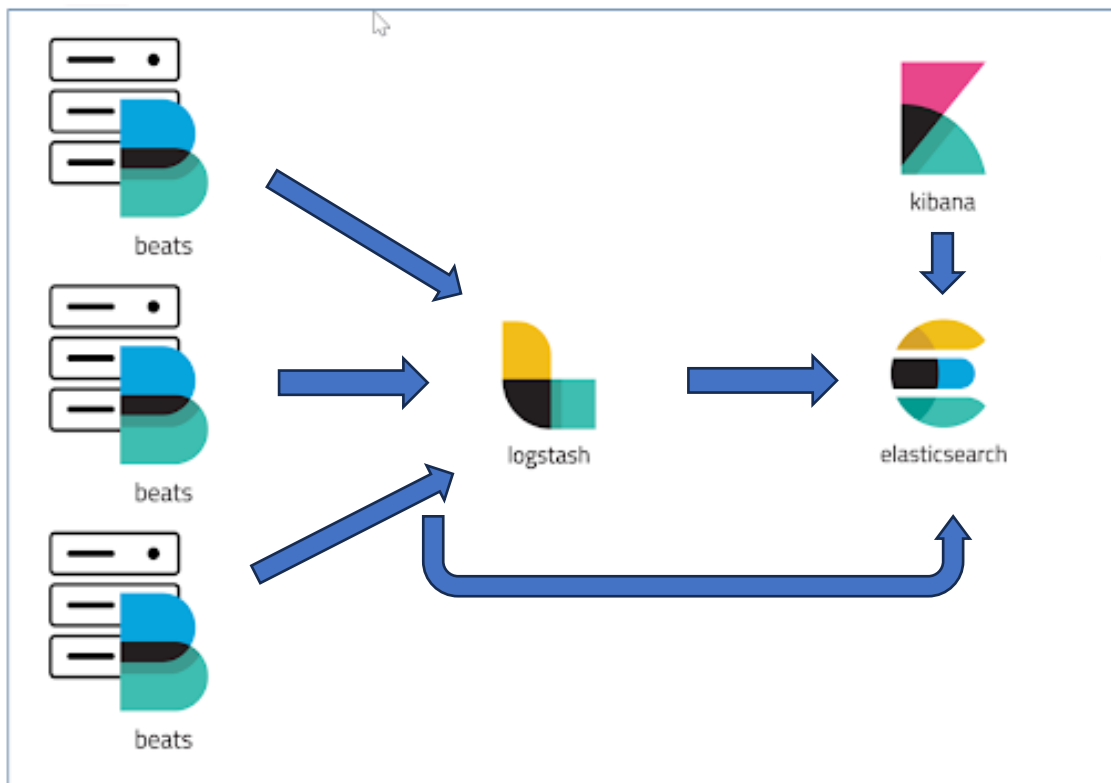


Imagen 1: Arquitectura general del sistema.

Logstash se encarga de captar los logs provenientes de Filebeat, filtrarlos y/o enriquecerlos y enviarlos a su índice correspondiente en Elasticsearch. Respecto a Filebeat, este es un agente ligero que se instala en los servicios para enviar directamente los logs a Elasticsearch o Logstash. Elasticsearch almacena los registros enviados por Logstash y los indexa mediante un motor de búsqueda de texto completo y capacidades de análisis distribuido. Por último, Kibana se utiliza para mostrar los datos almacenados en Elasticsearch de forma gráfica, accediendo a Elasticsearch a través de su API de tipo REST.

A continuación, se explican en detalle estos aplicativos.

2.1. Logstash

La función principal de Logstash es transformar datos inicialmente sin estructura, como los logs crudos obtenidos de distintos servicios, organizándolos e incorporando metadatos como tipo, fecha, hora, host, y convertirlos en formato JSON para su almacenamiento en Elasticsearch.

Logstash además proporciona filtros para extraer campos específicos de los logs o realizar otras tareas de procesamiento.

En la imagen 2 se puede ver desde Kibana el formato estándar que Logstash aplica a los logs en crudo que recibe.

Time ▾	_source
Feb 5, 2024 @ 14:58:06.731	<pre> @version: 1 type: cassandra @timestamp: Feb 5, 2024 @ 14:58:06.731 path: /usr/share/logstash/cassandra_data/logs/gc.log host: 2887cf6bb99d message: [2024-02-05T13:58:06.035+0000][12413.474s][1][140][trace] CMS: promo attempt is safe: available(1497666200) >= av_promo(24423624), max_promo(125781024) _id: 3riPeY0BolzNDCSB2Frz _type: _doc _index: logstash-cassandra-2024.02.05 _score: - </pre>
Feb 5, 2024 @ 14:57:56.708	<pre> @version: 1 type: cassandra @timestamp: Feb 5, 2024 @ 14:57:56.708 path: /usr/share/logstash/cassandra_data/logs/gc.log host: 2887cf6bb99d message: [2024-02-05T13:57:56.036+0000][12403.474s][1][140][trace] CMS: promo attempt is safe: available(1497666200) >= av_promo(24423624), max_promo(125781024) _id: 2biPeY0BolzNDCSBsVrL _type: _doc _index: logstash-cassandra-2024.02.05 _score: - </pre>

Imagen 2: Formato de logs proporcionado por Logstash por defecto.

Como se puede observar, Logstash por defecto, sin añadir ningún filtro, incorpora los siguientes campos a los logs para darles una estructura consultable:

- **type:** Indica el servicio del que proviene el log, a no ser que se esté usando Filebeat, en ese caso, tomará el valor “Filebeat” independientemente del servicio que haya generado el log.
- **@version:** Este campo es irrelevante, hace referencia a la versión del esquema del log en Logstash, normalmente tomará el valor 1.
- **path:** Es la ruta donde se encuentra el fichero del cual se obtuvo el log.
- **host:** En este proyecto, este campo identifica el contenedor donde se generó el log, en otros casos podría contener el nombre del host de donde proviene el log.
- **@timestamp:** Es el valor temporal de referencia que utiliza Logstash, indica la fecha y hora del momento en que Logstash recibió el log.
- **message:** Indica el mensaje principal del log, suele contener gran parte de este.
- **_id:** Este campo sirve para identificar cada log (documento json) dentro de cada colección de documentos de Elasticsearch, obviamente tiene un valor único.
- **_type:** Este campo ya no se utiliza (deprecated).
- **_index:** Nombre del índice de Elasticsearch donde se ha almacenado este log.
- **_score:** Indica cómo de importante es un documento en referencia a una consulta de búsqueda determinada. En este proyecto no se ha utilizado.

Cabe señalar que, estos campos los generará por defecto Logstash en caso de que el input recibido sea un log en crudo; sin embargo, si se utiliza Filebeat, el log recibido en Logstash ya será un documento json y tendrá el formato de campos determinado por Filebeat.

2.2. Elasticsearch

Para almacenar la información, Elasticsearch se basa en índices [12]. Un índice es un conjunto de documentos JSON y cada documento JSON es un conjunto de campos clave-valor, los cuales contienen los datos del log.

Cuando Elasticsearch recibe un log lo indexa [16] junto con un atributo de tipo timestamp que es añadido automáticamente por Elasticsearch para guardar el instante en que llegaron esos datos y facilitar futuras búsquedas.

Una característica de Elasticsearch utilizada en este proyecto y propia de la tecnología NoSQL es que no es necesario definir la estructura del fichero JSON a indexar previamente (schemaless), es decir, puede importar datos sin necesidad de haber definido el esquema anteriormente.

Con los datos ya almacenados, se puede realizar la búsqueda y análisis de datos. Elasticsearch proporciona una API basada en JSON RESTful para buscar, indexar, actualizar y eliminar documentos dentro de un índice mediante peticiones HTTP. Una de las principales características de Elasticsearch es que través de esta interfaz se pueden realizar búsquedas por texto completo (full-text) casi en tiempo real.

Otra característica importante de Elasticsearch es su escalabilidad. Emplea shards para distribuir los documentos y ser indexados en diferentes nodos de forma redundante y permitir consultas concurrentes.

En este proyecto se utiliza la funcionalidad de Elasticsearch de importar logs sin haber definido un esquema previamente, en referencia a ello, se puede configurar los índices de dos formas:

- **Estáticamente:** Se consideran índices estáticos los índices sobre los que se ha definido previamente el tipo de datos que va a almacenar (JSON schema). Es útil en casos en los que se quieran restringir los campos de los documentos que formarán parte del índice. Permite definir tanto los campos que existirán como cuales de ellos contendrán texto, números, fechas.
- **Dinámicamente:** Todos los índices sobre los que no se define un esquema previamente son dinámicos por defecto. En este caso Elasticsearch intenta detectar el tipo de dato recibido y darle el formato que cree adecuado.

La API de Elasticsearch, que es utilizada principalmente por Kibana, permite buscar, indexar, actualizar y eliminar datos almacenados en Elasticsearch mediante el lenguaje de consulta Query DSL basado en JSON.

2.3. Kibana

Kibana es el punto final del flujo de datos, es una plataforma de código abierto que permite la visualización de datos mediante dashboards, gráficos y todo tipo de elementos visuales. Kibana es ampliamente usado para análisis de logs, análisis de seguridad y análisis de datos en diferentes sectores.

Kibana utiliza la API basada en JSON RESTful disponible en Elasticsearch, a través de la cual se pueden hacer consultas de todo tipo, por palabras, campos, fechas, etc.

Kibana contiene múltiples funcionalidades, algunas de ellas de pago, en este proyecto se usarán las funciones principales gratuitas, que se explicarán con un caso de uso más adelante.

2.4. Filebeat

Los beats son agentes ligeros que se pueden instalar en los servicios para enviar directamente los logs a Elasticsearch o Logstash.

Filebeat permite enviar los logs tanto a Logstash como a Elasticsearch. En caso de que los logs necesiten ser procesados o filtrados sería necesario pasar por Logstash; en caso contrario, se podrían almacenar en Elasticsearch directamente.

Filebeat es especialmente útil cuando se generan logs en múltiples servicios, ya que instalando y configurando Filebeat en cada equipo sería suficiente para enviar los logs a Logstash o Elasticsearch. En el caso de un despliegue local en un mismo equipo se podría evitar el uso de Filebeat almacenando los logs en el equipo e indicando a Logstash su localización mediante *bind mounts* o volúmenes. Sin embargo, para darle un contexto más realista y poder utilizar una función de Kibana que necesita Filebeat se empleará este en el proyecto.

3. Despliegue de la plataforma big data y del Stack ELK en entorno local

Para el despliegue de la plataforma se ha decidido emplear Docker y Docker Compose [10]. Los principales motivos son los siguientes:

- **Aislamiento entre servicios:** Cada aplicación se ejecuta con sus dependencias en un contenedor independiente y aislado, lo que mejora la seguridad y reduce los conflictos entre aplicaciones.
- **Entornos de desarrollo y producción idénticos:** Docker soluciona el conocido problema "funciona en mi máquina" ya que los contenedores se pueden ejecutar en cualquier entorno que soporte Docker sin realizar ningún cambio.
- **Facilidad de despliegue y modificación:** Con Docker Compose, el despliegue se hace únicamente a través de un archivo y un solo comando. Esta es la estrategia habitual en aplicaciones big data desplegadas en la nube.
- **Portabilidad:** Docker encapsula aplicaciones y dependencias en contenedores, esto permite que puedan ser ejecutados en cualquier entorno compatible con Docker sin necesidad de realizar ningún cambio.
- **Escalabilidad:** Docker permite la creación de múltiples réplicas de un contenedor para repartir la carga de trabajo.
- **Uso de recursos:** A diferencia de las máquinas virtuales, los contenedores de Docker utilizan el mismo kernel que el sistema operativo, además son más ligeros y ocupan menos espacio en memoria RAM y disco.

3.1. Configuración del fichero .yaml de despliegue

A continuación, se muestra el fichero que se ha utilizado para el despliegue de los contenedores utilizados en el proyecto, tanto de la plataforma big data descrita en el apartado 1.3 como de las herramientas del stack ELK.

La configuración de zookeeper es prácticamente por defecto, solo destacar que todos los contenedores se añadirán a la red "storm" y todos los servicios de la plataforma big data tendrán su propio volumen donde almacenar los logs, como se muestra subrayado en amarillo.

```
version: '3.7'

services:
  zookeeper:
    image: zookeeper
    container_name: zookeeper
    restart: always
    networks:
      - storm
    environment:
      ZOO_MY_ID: 1
      ZOO_SERVERS: server.1=0.0.0.0:2888:3888;2181
    ports:
      - "2181:2181"
      - "2888:2888"
      - "3888:3888"
    volumes:
      - zookeeper_logs:/var/log/zookeeper
```


Los servicios Spark se configuran como master y worker respectivamente, se asigna un volumen para los logs de cada uno de ellos y se exponen los puertos. En el master se exponen dos puertos, uno para la comunicación con los workers y otro para su interfaz, en cambio los workers solo tienen un puerto para la interfaz web.

```
spark-master:
  image: bitnami/spark:2.4.5
  networks:
    - storm
  restart: always
  environment:
    - SPARK_MODE=master
  ports:
    - "7077:7077"
    - "8080:8080"
  volumes:
    - sparkmaster_logs:/opt/bitnami/spark/logs
```

```
spark-worker:
  image: bitnami/spark:2.4.5
  networks:
    - storm
  environment:
    - SPARK_MODE=worker
    - SPARK_MASTER_URL=spark://spark-master:7077
  ports:
    - "8081:8081"
  restart: always
  volumes:
    - sparkworker_logs:/opt/bitnami/spark/logs
```

El despliegue de Kafka utiliza la imagen expone el puerto 9092. Se configura para que interactúe con Zookeeper (zookeeper:2181) y utilice autenticación y autorización mediante SASL_PLAINTEXT. La variable KAFKA_OPTS indica el fichero con las credenciales correctas, el cual se localiza en la raíz del contenedor tras haberlo mapeado con un volumen. También se montan volumen para los logs y varios archivos de configuración para utilizar credenciales como cliente. El contenedor se conecta a la red storm.

```

kafka:
  image: wurstmeister/kafka
  container_name: kafka
  ports:
    - "9092:9092"
  environment:
    HOSTNAME: kafka
    HOSTNAME_COMMAND: "docker info | grep 'Node Address: ' | cut -d' '
-f 5"
    KAFKA_ZOOKEEPER_CONNECT: zookeeper:2181

    # Activar autenticación y autorización
    KAFKA_ADVERTISED_LISTENERS: SASL_PLAINTEXT://localhost:9092
    KAFKA_LISTENERS: SASL_PLAINTEXT://:9092
    KAFKA_INTER_BROKER_LISTENER_NAME: SASL_PLAINTEXT
    KAFKA_AUTHORIZER_CLASS_NAME:
kafka.security.authorizer.AclAuthorizer
    KAFKA_SUPER_USERS: User:admin;User:admin2
    KAFKA_SASL_MECHANISM_INTER_BROKER_PROTOCOL: PLAIN
    KAFKA_SASL_ENABLED_MECHANISMS: PLAIN
    KAFKA_OPTS: "-Djava.security.auth.login.config=/jaas.conf"
  volumes:
    - /var/run/docker.sock:/var/run/docker.sock
    # Volumen con los logs de Kafka
    - kafka_logs:/opt/kafka/logs
    # Definición de credenciales
    - C:/TFGLogs/jaas.conf:/jaas.conf
    # Credenciales incorrectas para autenticación
    - C:/TFGLogs/client.properties:/client.properties
    # Credenciales correctas para autenticación
    - C:/TFGLogs/admin.properties:/admin.properties
    # Credenciales usuario1 correctas
    - C:/TFGLogs/producer.properties:/producer.properties
    # Credenciales usuario2 correctas
    - C:/TFGLogs/consumer.properties:/consumer.properties
  networks:
    - storm

```

```

cassandra:
  image: cassandra
  container_name: cassandra
  networks:
    - storm
  volumes:
    - cassandra_logs:/var/log/cassandra
  environment:
    CASSANDRA_BROADCAST_ADDRESS: cassandra
    CASSANDRA_CLUSTER_NAME: POLLUTION_CLUSTER
    CASSANDRA_ENDPOINT_SNITCH: GossipingPropertyFileSnitch
    CASSANDRA_DC: dc1
    CASSANDRA_RACK: rack1
    CASSANDRA_SEEDS: cassandra
  ports:
    - "9042:9042"

```

En el despliegue de Elasticsearch se exponen dos puertos, el 9200, utilizado para la API REST, y el 9300, necesario para la comunicación interna entre nodos del clúster de Elasticsearch. Aunque en este despliegue se usa un solo nodo (“discovery.type=single-node”), el puerto sigue siendo necesario para cualquier posible configuración futura.

```

elasticsearch:
  image: docker.elastic.co/elasticsearch/elasticsearch:7.9.3
  environment:
    - discovery.type=single-node
  ports:
    - "9200:9200"
    - "9300:9300"
  networks:
    - storm

```

En el despliegue de Logstash se sitúan los archivos de configuración en su directorio correspondiente, se expone el puerto 5044 para recibir datos de otras aplicaciones y, además, se indica que depende del servicio elasticsearch.

```

logstash:
  image: docker.elastic.co/logstash/logstash:7.9.3
  volumes:
    # Ficheros de configuracion de Logstash
    - C:/TFGLogs/logstash/logstash_config:/usr/share/logstash/config
    - C:/TFGLogs/logstash/logstash_pipeline:/usr/share/logstash/pipeline
  ports:
    - "5044:5044"
  depends_on:
    - elasticsearch
  networks:
    - storm

```

Kibana se configura para funcionar en el puerto 5601, permitiendo así el acceso a su interfaz web. Se establece una conexión con Elasticsearch utilizando las variables de entorno ELASTICSEARCH_URL y ELASTICSEARCH_HOSTS. Kibana depende del servicio elasticsearch para funcionar y se conecta a la red storm, la cual utiliza el driver de red “bridge” para la comunicación entre contenedores.

```
kibana:
  image: docker.elastic.co/kibana/kibana:7.9.3
  ports:
    - "5601:5601"
  environment:
    ELASTICSEARCH_URL: http://elasticsearch:9200
    ELASTICSEARCH_HOSTS: http://elasticsearch:9200
  depends_on:
    - elasticsearch
  networks:
    - storm
networks:
  storm:
    driver: bridge
```

En Filebeat, se monta tanto el fichero de configuración como el volumen con los logs de Kafka, que serán los utilizados en el caso de uso. En el momento que fuese necesario monitorizar los logs de los demás servicios solo habría que montar su volumen correspondiente.

```
filebeat:
  image: docker.elastic.co/beats/filebeat:7.9.3
  user: root
  volumes:
    - /var/lib/docker/containers:/var/lib/docker/containers:ro
    - /var/run/docker.sock:/var/run/docker.sock:ro
    # Archivo de configuración
    - C:/TFGLogs/filebeat.yml:/usr/share/filebeat/filebeat.yml
    # Volumen con los logs de Kafka
    - kafka_logs:/usr/share/filebeat/kafka_logs
  networks:
    - storm
  depends_on:
    - kafka
    - zookeeper
    - cassandra
    - elasticsearch
    - logstash
  command: filebeat -e -strict.perms=false
  networks:
    - storm
```

En este último apartado se definen los volúmenes para almacenar los logs de cada servicio de la plataforma big data.

```
volumes:
  kafka_logs:
    external: true
  zookeeper_logs:
    external: true
  sparkmaster_logs:
    external: true
  sparkworker_logs:
    external: true
  cassandra_logs:
    external: true
```

3.2. Configuración de logs de Kafka

Para un sistema de gestión de logs, los ficheros más relevantes son los logs de aplicación, ya que proporcionan información directa sobre el estado de salud, seguridad y rendimiento del cluster de Kafka.

En Kafka, los registros se clasifican generalmente en dos tipos: registros de bróker (o aplicación) y registros de datos (o tópicos). La configuración de estos registros se puede ajustar en el directorio “/opt/kafka/config”. Los archivos de configuración más cruciales incluyen “server.properties”, que especifica la ubicación de los registros de datos, y “log4j.properties”, que establece el nivel de registro y los archivos para los registros del bróker. A continuación, se explican los dos tipos de logs mencionados previamente.

- **Logs de datos/tópicos:** En este proyecto se encuentran en la ruta /kafka/kafka-logs-kafka, estos ficheros están relacionados con el almacenamiento de los datos en los tópicos, contienen los propios datos y metadatos.
- **Logs de aplicación/bróker:** En este proyecto se encuentran en la ruta /opt/kafka/logs, incluyen información sobre el funcionamiento del servidor de Kafka.

3.2.1. Ficheros de logs de Kafka

controller.log: En este fichero se registran las actividades del controlador de Kafka, como gestionar errores en otros brokers (otras instancias de Kafka), gestionar quién es el líder de las particiones, hacer el rebalanceo de cargas si es necesario, gestionar los cambios de estado de las particiones e incluso gestionar los metadatos del clúster.

kafka-authorizer.log: Inicialmente no se generan logs en este fichero, es necesario configurar la autorización y autenticación de Kafka para ello. Como se puede deducir, aquí se almacenan los errores de autorización.

kafka-request.log: En este fichero se almacena información sobre las solicitudes de los clientes, es útil para visualizar el comportamiento del cliente y posibles errores durante la comunicación cliente-servidor.

log-cleaner.log: Este fichero registra información sobre el proceso conocido como “compactación de logs”, el cual ayuda a mantener el tamaño de los logs manejable y optimiza el uso del almacenamiento eliminando entradas de log antiguas o duplicadas que ya no son necesarias.

server.log: Es el fichero más importante, ya que registra la actividad general del servidor. Entre otros eventos, también registra los fallos de autenticación (si está activada la autenticación).

state-change.log: Es un fichero poco importante, almacena detalles cada vez que hay un cambio en el estado de las particiones dentro de un broker de Kafka. Este puede incluir eventos cuando una partición se activa, se desactiva, o cuando cambia de líder.

kafkaServer-gc.log: También es un fichero poco importante, simplemente contiene información sobre la recolección de basura de Java.

3.2.2. Autenticación vs Autorización en Kafka

De cara a monitorizar los logs de autenticación y autorización de Kafka, es importante conocer como Kafka maneja la autenticación y la autorización y diferenciar los dos conceptos:

- **Autenticación:** Los fallos de autenticación aparecen en el fichero “server.log”. La autenticación es correcta si el usuario con el que se quiere acceder a Kafka está definido en las credenciales válidas de Kafka, incorrecta en caso contrario.
- **Autorización:** La autorización se refiere al proceso de decidir si un usuario, ya previamente autenticado de forma correcta, tiene permiso para realizar una acción específica, como leer o escribir en un tópico. Los eventos relacionados específicamente con la autorización se registran en “kafka-authorizer.log”. Para que funcione la autorización es necesario haber definido ACL’s (listas de control de acceso) previamente. Aquellas acciones sobre las que no se defina un permiso con ACL’s serán denegadas por Kafka.

3.2.3. Configuración de la autenticación/autorización de acceso de Kafka

Para activar la autenticación/autorización es necesario llevar a cabo modificaciones en el fichero de configuración “server.properties” de Kafka [18]. En este caso al estar trabajando con contenedores la mejor opción es modificar el fichero a través de las variables de entorno de la imagen de Kafka.

Se muestra a continuación la configuración de SASL_PLAINTEXT en Kafka:

```
KAFKA_ADVERTISED_LISTENERS: SASL_PLAINTEXT://localhost:9092
KAFKA_LISTENERS: SASL_PLAINTEXT://:9092
KAFKA_INTER_BROKER_LISTENER_NAME: SASL_PLAINTEXT
KAFKA_AUTHORIZER_CLASS_NAME: kafka.security.authorizer.AclAuthorizer
KAFKA_SUPER_USERS: User:admin;User:admin2
KAFKA_SASL_MECHANISM_INTER_BROKER_PROTOCOL: PLAIN
KAFKA_SASL_ENABLED_MECHANISMS: PLAIN
KAFKA_OPTS: "-Djava.security.auth.login.config=/jaas.conf"
```

Para definir las credenciales válidas es necesario crear un archivo como el que se muestra a continuación:

```
KafkaServer {  
    org.apache.kafka.common.security.plain.PlainLoginModule required  
    username="admin"  
    password="admin"  
    user_admin="admin"  
    user_usuario1="usuario1"  
    user_usuario2="usuario2";  
};
```

En el cliente, para utilizar SASL_PLAINTEXT, se referencia en los comandos de producción, consumición o configuración de Kafka a un fichero donde se definen las credenciales que se están usando, como el siguiente:

```
security.protocol=SASL_PLAINTEXT  
sasl.mechanism=PLAIN  
sasl.jaas.config=org.apache.kafka.common.security.plain.PlainLoginModule  
required username="admin" password="admin";
```

De forma que para crear un tópico utilizando SASL_PLAINTEXT se referencia al fichero con las credenciales de la siguiente manera:

```
docker exec kafka /opt/kafka/bin/kafka-topics.sh --create --topic topico1  
--bootstrap-server kafka:9092 --replication-factor 1 --partitions 1 --  
command-config /admin.properties
```

En este punto ya está configurada la autenticación de Kafka, ahora es necesario configurar la autorización, es decir, crear ACL's para definir los permisos de acceso.

La creación de una ACL para permitir al usuario usuario1 producir datos en el topico1 y al usuario2 leer del topico1 se hace mediante los siguientes comandos:

```
docker exec -it kafka kafka-acls.sh --bootstrap-server localhost:9092 --  
command-config /admin.properties --add --allow-principal User:usuario1 --  
operation Write --topic topico1
```

```
docker exec -it kafka kafka-acls.sh --bootstrap-server localhost:9092 --  
command-config /admin.properties --add --allow-principal User:usuario2 --  
operation Read --group '*' --topic topico1
```

Para revisar la lista de ACL's creadas podemos ejecutar el siguiente comando:

```
docker exec -it kafka kafka-acls.sh --bootstrap-server localhost:9092 --  
command-config /admin.properties --list
```

Con objeto de generar eventos de log tenemos que simular el entorno enviando y leyendo mensajes, para ello se utilizarán los siguiente comandos.

Para enviar un mensaje al topico1:

```
# CORRECTO (el usuario1 puede escribir en el topico1)

docker exec -it kafka kafka-console-producer.sh --broker-list
localhost:9092 --topic topico1 --producer.config producer.properties

# INCORRECTO (el usuario2 no puede escribir en el topico1)

docker exec -it kafka kafka-console-producer.sh --broker-list
localhost:9092 --topic topico1 --producer.config consumer.properties
```

Y para leer el topico1:

```
# CORRECTO (el usuario2 puede leer del topico1)

docker exec -it kafka kafka-console-consumer.sh --bootstrap-server
localhost:9092 --topic topico1 --from-beginning --consumer.config
consumer.properties

# INCORRECTO (el usuario1 no puede leer del topico1)

docker exec -it kafka kafka-console-consumer.sh --bootstrap-server
localhost:9092 --topic topico1 --from-beginning --consumer.config
producer.properties
```

4. Diseño de la solución en entorno local

En este apartado se describe el diseño global de la solución para la gestión de logs, enfocándose en el caso de uso de autenticación y autorización en Kafka. A continuación, se detalla la estrategia para la monitorización de logs, su organización en Elasticsearch y su visualización en Kibana.

El objetivo principal de la monitorización de logs en este proyecto es detectar y registrar todas las actividades de acceso no autorizado.

Para cumplir con el objetivo establecido, se han identificado y seleccionado los siguientes logs de Kafka:

- **Logs de autenticación:** Registran los intentos de conexión fallidos. Estos logs se encuentran en el fichero “server.log”. A continuación, se muestra el formato de estos:

```
[2024-04-22 15:23:34,795] INFO [SocketServer listenerType=ZK_BROKER,
nodeId=1001] Failed authentication with /172.18.0.1 (Unexpected Kafka
request of type METADATA during SASL handshake.)
(org.apache.kafka.common.network.Selector)
```

- **Logs de autorización:** Registran los intentos de acceso por parte de usuarios autenticados a recursos sobre los que no tienen permisos. Estos logs se encuentran en el fichero “kafka-authorizer.log”. A continuación, se muestra el formato de estos:

```
[2024-04-27 12:36:55,192] INFO Principal = User:usuario2 is Denied
Operation = Create from host = 127.0.0.1 on resource =
Topic:LITERAL:topico1 for request = CreateTopics with resourceRefCount = 1
(kafka.authorizer.logger)
```


Los logs se organizan en Elasticsearch en dos índices separados para optimizar su gestión y consulta, estos índices se crearán automáticamente de forma mensual, sin embargo, esto dependerá del contexto en el que se desarrolle el proyecto y puede variar.

Los campos clave de los logs de autenticación y autorización son los marcados en amarillo en los dos cuadros siguientes:

```
@timestamp Apr 22, 2024 @ 17:23:35.715
_index logstash-kafka-autenticacion-2024.04
ip 172.18.0.1
log_source kafka
log_type autenticación
message
[2024-04-22 15:23:34,795] INFO [SocketServer listenerType=ZK_BROKER,
nodeId=1001] Failed authentication with /172.18.0.1 (Unexpected Kafka
request of type METADATA during SASL handshake.)
(org.apache.kafka.common.network.Selector)
```

```
@timestamp Apr 22, 2024 @ 17:23:35.715
_index logstash-kafka-autorizacion-2024.04
log_source kafka
log_type autorizacion
message
[2024-04-22 15:23:34,795] INFO [SocketServer listenerType=ZK_BROKER,
nodeId=1001] Failed authentication with /172.18.0.1 (Unexpected Kafka
request of type METADATA during SASL handshake.)
(org.apache.kafka.common.network.Selector)
operation Create
request_type CreateTopics
resource_name topico1
resource_type Topic
usuario usuario2
```

Para la visualización de la información en Kibana se creará un dashboard específico con gráficos para mostrar:

- El número de fallos de autorización por usuario del sistema
- El número de fallos de autenticación por ip
- Fallos de autorización por usuario en el dominio del tiempo
- Fallos de autenticación por ip en el dominio del tiempo
- Tipos de operaciones de autorización denegadas
- Tipos de peticiones de autorización denegadas
- Tipo de recursos a los que se intenta acceder
- Recursos específicos a los que se intenta acceder

Esta solución asegura una monitorización eficiente y una gestión estructurada de los logs, permitiendo una rápida identificación y resolución de problemas relacionados con la seguridad y el acceso a recursos de Kafka.

4.1. Configuración del Stack ELK

Se ha mostrado previamente el despliegue de los contenedores con Docker, después del despliegue es necesario configurar las herramientas del stack ELK para su funcionamiento.

4.1.1. Filebeat

Como se dijo previamente, se utiliza Filebeat en el proyecto, por lo que es necesario configurarlo para recoger los logs de los servicios y enviárselos a Logstash, de forma que Logstash procese y filtre los logs para enviárselos a su vez a Elasticsearch.

A continuación, se muestra el fichero “filebeat.yml” de configuración de Filebeat:

```
filebeat.inputs:
- type: log
  enabled: true
  paths:
    - /usr/share/filebeat/kafka_logs/server.log # Logs de server.log
    (fichero donde están los logs de autenticación)
  fields:
    log_source: kafka
    log_type: autenticacion
  fields_under_root: true

- type: log
  enabled: true
  paths:
    - /usr/share/filebeat/kafka_logs/kafka-authorizer.log # Fichero con
    los logs de autorización
  fields:
    log_source: kafka
    log_type: autorizacion
  fields_under_root: true

output.logstash:
  hosts: ["logstash:5044"]
```

En este proyecto Filebeat se empezó a utilizar después de probar el funcionamiento del sistema solamente con Logstash. Por esto, se ha comprobado que al integrar Filebeat pueden surgir ciertos problemas. Uno de estos es que Filebeat es el primero en acceder a los logs en crudo, formateándolo y convirtiéndolo a json, que es enviado a Logstash y que afectará al criterio de filtrado.

Por ejemplo, usando Filebeat, al llegar los logs a Logstash, el campo “type” es siempre “Filebeat”, en vez de “Kafka”, “Cassandra” o el nombre del servicio determinado de donde provengan los logs, por lo que si en Logstash se utilizaba el campo “type” para filtrar los logs según su origen será necesario modificar este filtrado para identificar el origen de los logs de otra forma, por ejemplo, creando en Filebeat un nuevo campo “log_source” y dándole un valor determinado en función de la ruta de donde procedan los logs.

Justo la estrategia mencionada de crear un campo “log_source” se ha aplicado en la configuración mostrada previamente y además se ha añadido otro campo “log_type” para identificar los logs de autenticación y autorización.

Por lo tanto, al utilizar Filebeat con la configuración anterior el formato de campos que llega a Logstash es el siguiente, se marca en amarillo los campos añadidos manualmente en Filebeat:

```
{
  "@timestamp" => 2024-04-06T14:21:30.826Z,
  "@version" => "1",
  "agent" => {
    "ephemeral_id" => "8ab4e6fa-4f73-4b51-bd19-a874b8c18226",
    "hostname" => "cd954ed329da",
    "id" => "9a51eb06-13c1-48d3-a185-41d449913adf",
    "name" => "cd954ed329da",
    "type" => "filebeat",
    "version" => "7.9.3"
  },
  "ecs" => {
    "version" => "1.5.0"
  },
  "host" => {
    "name" => "cd954ed329da"
  },
  "input" => {
    "type" => "log"
  },
  "log" => {
    "file" => {
      "path" => "/usr/share/filebeat/kafka_logs/server.log"
    },
    "offset" => 79992
  },
  #Campos añadidos manualmente
  "log_source" => "kafka",
  "log_type" => "autenticacion",
  "message" => "[2024-04-06 14:21:30,677] INFO [SocketServer
listenerType=ZK_BROKER, nodeId=1001] Failed authentication with /127.0.0.1
(Unexpected Kafka request of type METADATA during SASL handshake.)
(org.apache.kafka.common.network.Selector)",
  "tags" => [
    "beats_input_codec_plain_applied"
  ]
}
```

4.1.2. Logstash

Como ya se ha indicado, Logstash será el encargado de recibir los logs desde Filebeat, filtrarlos y enviarlos a Elasticsearch para su almacenamiento. A continuación, se explica su configuración.

4.1.2.1. Ficheros de configuración

Logstash tiene dos ficheros de configuración principales:

logstash.conf: archivo que se usa para definir la configuración de entrada, filtro y salida de logs. Se muestra a continuación la configuración utilizada para recibir los logs de autenticación y autorización desde Filebeat, filtrarlos y enviarlos a su índice correspondiente en Elasticsearch.

Comienza estableciendo un canal para recibir datos desde Filebeat a través del puerto 5044. Luego, aplica filtros específicos dependiendo del tipo de log: para los

de autenticación, busca el mensaje de error “Failed authentication” y extrae la dirección IP usando el plugin grok. En el caso de los logs de autorización, también se utiliza grok para detallar el usuario, la operación intentada, la IP del host, así como detalles del recurso y el tipo de solicitud realizada.

Finalmente, dependiendo de si el log es de autenticación o autorización, estos se envían a índices distintos en Elasticsearch.

```
input {
  beats {
    port => 5044
  }
}
```

```
filter {
  if [log_type] == "autenticacion" {
    # Filtrar solo los mensajes de autenticación fallida
    if [message] =~ /Failed authentication/ {
      grok {
        match => { "message" => "Failed authentication with %{IP:ip}" }
      }
    } else {
      drop { }
    }
  } else if [log_type] == "autorizacion" {
    grok {
      match => {
        "message" => [
          "\[.*\] INFO Principal = User:%{USERNAME:usuario} is Denied
          Operation = %{WORD:operation} from host = %{IP:host_ip} on resource =
          %{WORD:resource_type}:%{WORD:literal}:%{NOTSPACE:resource_name} for request
          = %{WORD:request_type}"
        ]
      }
    }
  }
}
```

```

output {
  if [log_type] == "autenticacion" {
    elasticsearch {
      hosts => ["http://elasticsearch:9200"]
      index => "logstash-kafka-autenticacion-%{+YYYY.MM}"
    }
  } else if [log_type] == "autorizacion" {
    elasticsearch {
      hosts => ["http://elasticsearch:9200"]
      index => "logstash-kafka-autorizacion-%{+YYYY.MM}"
    }
  }
  stdout { codec => rubydebug }
}

```

La siguiente línea de código sirve para enviar la salida de los eventos procesados a la consola estándar (stdout) de Logstash, además imprime los eventos en un formato fácil de leer para el usuario. Esto puede ser útil durante el desarrollo ya que permite ver en tiempo real como Logstash está procesando los datos. Sin embargo, en entornos de producción o cuando se procesan grandes volúmenes de datos, es común eliminar esta línea para evitar una sobrecarga innecesaria y mejorar el rendimiento.

```
stdout { codec => rubydebug }
```

- **logstash.yml:** se utiliza para configurar opciones de Logstash, como parámetros de JVM, nivel de logging y otros ajustes del sistema, se observa la configuración utilizada, que en este caso es una configuración por defecto.

```

path.config: /usr/share/logstash/pipeline
log.level: info
# Los niveles de log pueden ser trace, debug, info, warning, error, y
fatales.
path.logs: /usr/share/logstash/logs

```

4.1.2.2. Plugin Grok

Una de las formas más comunes de filtrar en Logstash es mediante el plugin Grok [14], este permite analizar texto aleatorio y convertirlo a un formato estructurado y consultable.

Por ejemplo, a los campos diseñados por defecto puede ser necesario añadir otros como el nivel de logging (INFO, WARN, ERROR), de forma que en Kibana se pueda filtrar por este campo.

Dependiendo del formato de los logs que se requiera procesar, se tendrá que utilizar el plugin Grok de una forma u otra, por lo que es importante examinar el formato de los archivos de logs previamente.

Para entender mejor la sintaxis de Grok se pondrá un ejemplo concreto. En este caso estamos tratando los logs de Kafka, más específicamente el log del fichero server.log, del que se muestra a continuación un ejemplo.

```
[2024-03-04 13:40:19,449] INFO [Log partition=topico1-0, dir=/kafka/kafka-logs-kafka] Loading producer state till offset 0 with message format version 2 (kafka.log.Log)
```

Aplicando el siguiente filtro con el plugin Grok se podrá estructurar los logs de este fichero en sus campos identificativos según su formato. Cabe destacar que los filtros se deben personalizar para cada fichero de log de cada servicio, ya que no hay un formato estandarizado, y si defines en los filtros un campo que no se detecta en ese fichero en concreto habrá errores en la visualización del log en Kibana.

Para darle un formato correcto a este log en concreto se usará este filtro Grok:

```
\[%{TIMESTAMP_ISO8601:log_timestamp}\] %{LOGLEVEL:log_level} \[Log partition=%{DATA:partition}, dir=%{PATH:log_dir}\] %{GREEDYDATA:message} \(%{JAVACLASS:java_class}\)
```

Sin embargo, la configuración de filtros para el fichero server.log de Kafka no acaba aquí, ya que este filtro solo será útil para el evento previo, pero en este fichero se almacenan decenas o cientos de logs con formatos un poco diferentes, por ejemplo:

```
[2024-03-04 13:38:45,525] INFO [GroupCoordinator 1001]: Starting up. (kafka.coordinator.group.GroupCoordinator)
```

Para este otro registro podríamos usar un filtro diferente, como el siguiente:

```
\[%{TIMESTAMP_ISO8601:log_timestamp}\] %{LOGLEVEL:log_level} \[%{DATA:component} %{INT:coordinator_id}\]: %{GREEDYDATA:message} \(%{JAVACLASS:java_class}\)
```

Ahora, si para un mismo fichero de logs de un servicio tenemos que usar diferentes filtros ¿cómo lo hacemos?

La respuesta es mediante el uso de la directiva match y el modificador “break_on_match => false”, esto permite intentar cada patrón de filtrado hasta que el formato del log coincida con uno de ellos.

Para complementar los dos filtros puestos como ejemplo previamente sobre el mismo fichero server.log del servicio Kafka el filtrado se establecería así:

```

filter {
  if [path] =~ /server\.log$/ and [type] == "kafka" {
    grok {
      break_on_match => false
      match => {
        "message" => [
          "\[%{TIMESTAMP_ISO8601:log_timestamp}\]"
          "%{LOGLEVEL:log_level}\[Log partition=%{DATA:partition},
          dir=%{PATH:log_dir}\] %{GREEDYDATA:log_message}
          \(%{JAVACLASS:java_class}\)",
          "\[%{TIMESTAMP_ISO8601:log_timestamp}\] %{LOGLEVEL:log_level}
          \[%{DATA:component} %{INT:coordinator_id}\]: %{GREEDYDATA:log_message}
          \(%{JAVACLASS:java_class}\)"
        ]
      }
      tag_on_failure => ["_grokparsefailure_serverlog"]
    }
  }
}

```

En el cuadro superior podemos ver un ejemplo de configuración de filtrado sobre el fichero server.log de Kafka, este filtrado se podría repetir para cada fichero incluyendo todos los formatos de logs que se detecten en cada uno de ellos.

La anotación “tag_on_failure” indica que a los logs que no coincidan con ninguno de los formatos de campos indicados se les añadirá el campo “tag_on_failure” con valor “_grokparsefailure_serverlog”. En caso de no querer que exista este campo y se trate por defecto a los logs que no coincidan se omitirá esta línea de código.

Como hemos visto previamente, puede ser muy complejo definir tantos campos específicos para cada log de cada fichero y servicio, por ello lo normal sería utilizar o los campos por defecto de Logstash o unos campos generales que sirvan para todos los logs, y posteriormente si hay un tipo de log que se quiera monitorizar especialmente, diseñar campos adicionales para ese caso en específico.

Por ejemplo, para la gestión de logs del servicio Kafka, vemos que de los 6 ficheros de logs solo hay uno que no sigue un patrón de FECHA-NIVEL-MENSAJE (aunque dentro del mensaje se podrían especificar más campos).

En la imagen 3 se muestra la estructura de 5 de los 6 ficheros de logs de Kafka:

```

[2024-03-18 10:54:12,577] INFO Registered broker 1001 at path /brokers/ids/1001 with addresses: INSIDE://kafka:9094,OUTSIDE://host.docker.internal:9092, czxid
[2024-03-18 10:54:12,654] INFO [ExpirationReaper-1001-topic]: Starting (kafka.server.DelayedOperationPurgatory$ExpiredOperationReaper)
[2024-03-18 10:54:12,667] INFO [ExpirationReaper-1001-Heartbeat]: Starting (kafka.server.DelayedOperationPurgatory$ExpiredOperationReaper)
[2024-03-18 10:54:12,670] INFO [ExpirationReaper-1001-Rebalance]: Starting (kafka.server.DelayedOperationPurgatory$ExpiredOperationReaper)
[2024-03-18 10:54:12,694] INFO [GroupCoordinator 1001]: Starting up. (kafka.coordinator.group.GroupCoordinator)
[2024-03-18 10:54:12,702] INFO [GroupCoordinator 1001]: Startup complete. (kafka.coordinator.group.GroupCoordinator)
[2024-03-18 10:54:12,750] INFO [ProducerId Manager 1001]: Acquired new producerId block (brokerId=1001,blockStartProducerId=2000,blockEndProducerId=2999) by w
[2024-03-18 10:54:12,751] INFO [TransactionCoordinator id=1001] Starting up. (kafka.coordinator.transaction.TransactionCoordinator)
[2024-03-18 10:54:12,755] INFO [TransactionCoordinator id=1001] Startup complete. (kafka.coordinator.transaction.TransactionCoordinator)
[2024-03-18 10:54:12,759] INFO [TransactionMarker Channel Manager 1001]: Starting (kafka.coordinator.transaction.TransactionMarkerChannelManager)
[2024-03-18 10:54:12,817] INFO [ExpirationReaper-1001-AlterAcls]: Starting (kafka.server.DelayedOperationPurgatory$ExpiredOperationReaper)
[2024-03-18 10:54:12,945] INFO [/config/changes-event-process-thread]: Starting (kafka.common.ZkNodeChangeNotificationListener$ChangeEventProcessThread)
[2024-03-18 10:54:12,978] INFO [SocketServer listenerType=ZK_BROKER, nodeId=1001] Starting socket server acceptors and processors (kafka.network.SocketServer)
[2024-03-18 10:54:12,988] INFO [SocketServer listenerType=ZK_BROKER, nodeId=1001] Started data-plane acceptor and processor(s) for endpoint : ListenerName(INS
[2024-03-18 10:54:12,995] INFO [SocketServer listenerType=ZK_BROKER, nodeId=1001] Started data-plane acceptor and processor(s) for endpoint : ListenerName(OUT
[2024-03-18 10:54:12,996] INFO [SocketServer listenerType=ZK_BROKER, nodeId=1001] Started socket server acceptors and processors (kafka.network.SocketServer)
[2024-03-18 10:54:13,006] INFO Kafka version: 2.8.1 (org.apache.kafka.common.utils.AppInfoParser)
[2024-03-18 10:54:13,007] INFO Kafka commitId: 839b886f9b732b15 (org.apache.kafka.common.utils.AppInfoParser)
[2024-03-18 10:54:13,007] INFO Kafka startTimeMs: 1710759252997 (org.apache.kafka.common.utils.AppInfoParser)
[2024-03-18 10:54:13,010] INFO [KafkaServer id=1001] started (kafka.server.KafkaServer)
[2024-03-18 10:54:13,063] INFO [ReplicaFetcherManager on broker 1001] Removed fetcher for partitions Set(topicol-0) (kafka.server.ReplicaFetcherManager)
[2024-03-18 10:54:13,073] INFO [Partition topicol-0 broker=1001] Log loaded for partition topicol-0 with initial high watermark 0 (kafka.cluster.Partition)
[2024-03-18 10:54:13,089] INFO [broker-1001-to-controller-send-thread]: Recorded new controller, from now on will use broker kafka:9094 (id: 1001 rack: null)

```

Imagen 3: Formato de logging de 5 ficheros de Kafka

En la imagen 4 se muestra la estructura del único fichero de Kafka que no cumple la estructura anterior:

```
[2024-03-18T10:54:11.383+0000][gc,start ] GC(0) Pause Young (Normal) (G1 Evacuation Pause)
[2024-03-18T10:54:11.385+0000][gc,task ] GC(0) Using 10 workers of 10 for evacuation
[2024-03-18T10:54:11.399+0000][gc,phases ] GC(0) Pre Evacuate Collection Set: 0.0ms
[2024-03-18T10:54:11.399+0000][gc,phases ] GC(0) Evacuate Collection Set: 13.0ms
[2024-03-18T10:54:11.400+0000][gc,phases ] GC(0) Post Evacuate Collection Set: 0.8ms
[2024-03-18T10:54:11.400+0000][gc,phases ] GC(0) Other: 2.5ms
[2024-03-18T10:54:11.401+0000][gc,heap ] GC(0) Eden regions: 51->0(44)
[2024-03-18T10:54:11.401+0000][gc,heap ] GC(0) Survivor regions: 0->7(7)
[2024-03-18T10:54:11.401+0000][gc,heap ] GC(0) Old regions: 2->2
[2024-03-18T10:54:11.402+0000][gc,heap ] GC(0) Humongous regions: 0->0
```

Imagen 4: Formato de logging de 1 fichero de Kafka

Para hacer una gestión simple y general de estos ficheros podemos definir unos campos para los 5 ficheros similares y otros campos distintos para el otro fichero, aquí un ejemplo de filtrado para este caso:

```
filter {
  if [type] == "kafka" {
    if [path] =~ /kafkaServer-gc\.log$/ {
      grok {
        match => {
          "message" => [
            "\[%{TIMESTAMP_ISO8601:timestamp}\]\[%{DATA:gc_tags}\]"
            "%{GREEDYDATA:gc_message}"
          ]
        }
      }
    }
  }
  else {
    grok {
      match => {
        "message" => [
          "\[%{TIMESTAMP_ISO8601:timestamp}\] %{LOGLEVEL:loglevel}"
          "%{GREEDYDATA:message}"
        ]
      }
    }
  }
}
```

Con esta última configuración de filtrado mostrada, vamos a visualizar desde Kibana (ver imagen 5) como se han generado los campos, y podemos observar como se ha generado el campo "loglevel":

```
type: kafka loglevel: INFO path: /usr/share/logstash/kafka_logs/broker/server.log timestamp: 2024-03-18 11:56:41,007
host: a53650cc2af4 @timestamp: Mar 18, 2024 @ 12:56:41.529 @version: 1 message: [2024-03-18 11:56:41,007] INFO [Partition topic01-0
broker=1001] Log loaded for partition topic01-0 with initial high watermark 0 (kafka.cluster.Partition), [Partition topic01-0 broker=1001]
Log loaded for partition topic01-0 with initial high watermark 0 (kafka.cluster.Partition) _id: 6GvRUY48Vi73tMBSxw0l _type: _doc
_index: logstash-kafka-2024.12 _score: -
```


Imagen 5: Visualización de campos en Kibana para los 5 ficheros

Y en la imagen 6 se muestran los logs del fichero tratado de forma diferente, en el que se ha añadido el campo "gc_tags":

```
type: kafka path: /usr/share/logstash/kafka_logs/broker/kafkaServer-gc.log timestamp: 2024-03-18T11:56:40.867+0000 host: a53650cc2af4
gc_tags: gc,marking @timestamp: Mar 18, 2024 @ 12:56:41.524 @version: 1 gc_message: GC(5) Concurrent Cleanup for Next Mark message:
[2024-03-18T11:56:40.867+0000][gc,marking ] GC(5) Concurrent Cleanup for Next Mark _id: sGVrUY4BVi73tMBSxwoi _type: _doc
_index: logstash-kafka-2024.12 _score: -
```

Imagen 6: Visualización de campos en Kibana para el fichero independiente

Como se puede observar en las imágenes 5 y 6, además de los 3 campos indicados para cada fichero, Logstash ha añadido los restantes campos por defecto, si quisiéramos eliminar alguno de estos campos podríamos usar la siguiente directiva:

```
mutate {
  remove_field => ["path", "host", "@version", "type"]
}
```

En este apartado se ha explicado el funcionamiento del plugin Grok con diferentes logs de Kafka, aunque no sean los de autenticación y autorización, cuyos filtros se muestran en la configuración del stack ELK.

4.1.3. Elasticsearch

A continuación, se explica la configuración de Elasticsearch. Como se ha explicado previamente, es una base de datos NoSQL que almacena en colecciones de documentos JSON.

En la práctica, la forma de configurar la creación automática de un índice mensual se gestiona desde el fichero de configuración de Logstash, donde se indica el output de los logs.

Elasticsearch permite configurar los campos que contendrán los logs de ese índice en concreto de forma estática, sin embargo, en este proyecto se usará el mapeo dinámico.

Con Elasticsearch desplegado y configurado, es importante monitorizar el estado del clúster. Este comando sirve para verificar el estado de salud del clúster de Elasticsearch:

```
curl -X GET "http://localhost:9200/_cat/health?v"
```

El siguiente comando sirve para verificar los índices que existen en el clúster, de forma que puedas verificar la configuración de los mismos. Es muy útil para solucionar errores:

```
curl http://localhost:9200/_cat/indices
```

Además, el comando curl también permite eliminar índices de esta forma:

```
curl -X DELETE "localhost:9200/index-name"
```

Se muestra en la imagen 7 la salida al comando de consulta de índices, de forma que se observe los índices creados por defecto por Elasticsearch.

```
C:\Users\jesus>curl http://localhost:9200/_cat/indices
green open .kibana-event-log-7.9.3-000001 eYxv0gzDQzmo0xJzHYwBGw 1 0 2 0 10.8kb 10.8kb
green open .apm-custom-link WPDONB0sTEepUtai38Y1cw 1 0 0 0 208b 208b
green open .kibana_task_manager_1 Uy0VJpnlSeiqaeekvhCn5Q 1 0 6 21 205.6kb 205.6kb
yellow open logstash-kafka-autenticacion-2024.04 GUh7oWld8QKCL8ATpN0Ue-g 1 1 81 0 113.8kb 113.8kb
green open .apm-agent-configuration KeJ108X0Tf-12XtQsQTshw 1 0 0 0 208b 208b
yellow open logstash-kafka-autorizacion-2024.04 L4Im7ZhXR2q2zeKaxEn_4g 1 1 7 0 90.7kb 90.7kb
green open .async-search ehFJu0MtSP0hiCYQpQ6ksw 1 0 1 2 68.7kb 68.7kb
green open .kibana_1 3hAqOPrXQiKdzV5uWtJ7Ww 1 0 147 11 10.5mb 10.5mb
```

Imagen 7: Índices por defecto de Elasticsearch

Elasticsearch por defecto tiene creados 6 índices con funciones predeterminadas:

- **.kibana-event-log-7.9.3-000001**: es un índice utilizado por Kibana para registrar errores, ejecuciones en segundo plano, alertas, etc.
- **.apm-custom-link**: es un índice utilizado por APM (Application Performance Monitoring) de Elasticsearch para almacenar enlaces personalizados.
- **.kibana_task_manager_1**: es un índice utilizado por Kibana para gestionar tareas en segundo plano.
- **.apm-agent-configuration**: índice utilizado por APM (Application Performance Monitoring) para almacenar configuraciones personalizadas de los agentes APM, de forma que se pueda configurar los agentes APM desde Kibana directamente.
- **.async-search**: índice utilizado por Elasticsearch para la función de búsqueda asíncrona (para consultas de larga duración).
- **.kibana_1**: es uno de los índices más importantes de Kibana, en él se almacenan los dashboards, visualizaciones, configuraciones, etc.

4.2. Cuadro de mandos - Kibana

En este proyecto la única fuente de datos de la que se extraerá la información para mostrar en el cuadro de mandos será Elasticsearch. Kibana tiene múltiples funcionalidades, en este proyecto se explorarán las más relevantes.

4.2.1. Observabilidad

El menú de observabilidad actúa como un panel de control general, proporcionando una visión resumida de métricas esenciales creadas por defecto por Kibana, como el volumen de logs recibidos. Para un análisis más detallado, por ejemplo, para examinar detalladamente los logs recibidos o para ver métricas más desglosadas acompañadas de representaciones gráficas, es necesario navegar a otras secciones más especializadas. Mientras que el menú de observabilidad es útil para monitorizar métricas generales, el menú de *analytics* es el que se utiliza para analizar los logs en profundidad, debido a que ofrece capacidades más avanzadas para este fin. A continuación, se muestra la imagen 8 con el menú de observabilidad.

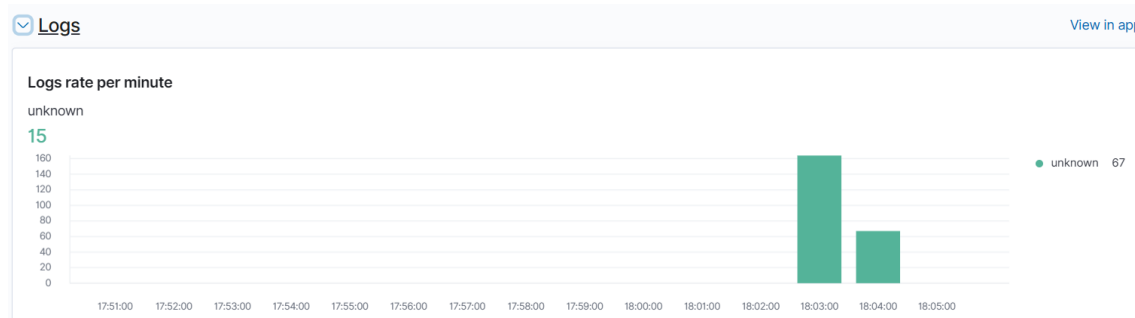


Imagen 8: Menú principal de Observability de Kibana

Para hacer uso del menú de observabilidad es necesario utilizar Filebeat, razón por la cual se incorporó en la solución del TFG.

4.2.2. Análisis

Kibana tiene funcionalidades de análisis que permiten al usuario visualizar los logs de diferentes maneras. El menú principal de análisis es “Discover”, en este menú se muestra toda la información de los logs recibidos, y permite al usuario crear filtros a su gusto para modificar la visualización.

En este caso, en la imagen 9 se muestra el filtro de visualización para un contexto en el que se quiera ver los intentos fallidos de acceso (autorización) del usuario usuario2.

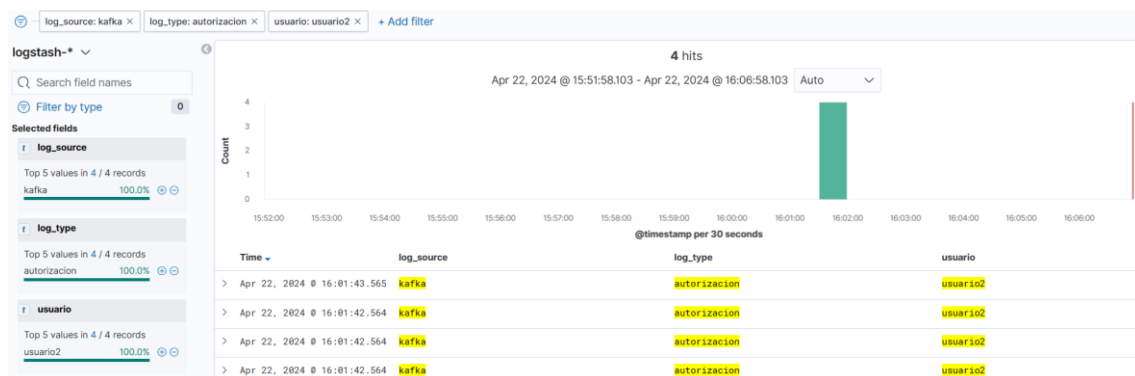


Imagen 9: Filtrado errores de acceso del usuario2

Este menú creado previamente se puede guardar con un nombre determinado para observarlo cuando sea necesario, esto puede ser útil para tener un panel con cada usuario, de forma que podemos vigilar su actividad y enterarnos en caso de que intenten acceder a algún tipo de información a la que no tienen acceso.

4.2.3. Dashboard y Lens

Dashboard es una función que depende de Lens. Lens facilita la creación de gráficos utilizando datos extraídos de los logs, permitiendo elegir entre varios tipos de gráficos y aplicar filtros como hemos hecho previamente en análisis. Dashboard, por su parte, recopila estos gráficos creados con Lens y los presenta en una interfaz unificada para su visualización. Esta capacidad de visualizar datos gráficamente es fundamental para detectar problemas de manera rápida y eficiente.

A continuación, se muestra en la imagen 10 un gráfico de líneas para visualizar los intentos de acceso denegados que han realizado diariamente los usuarios.

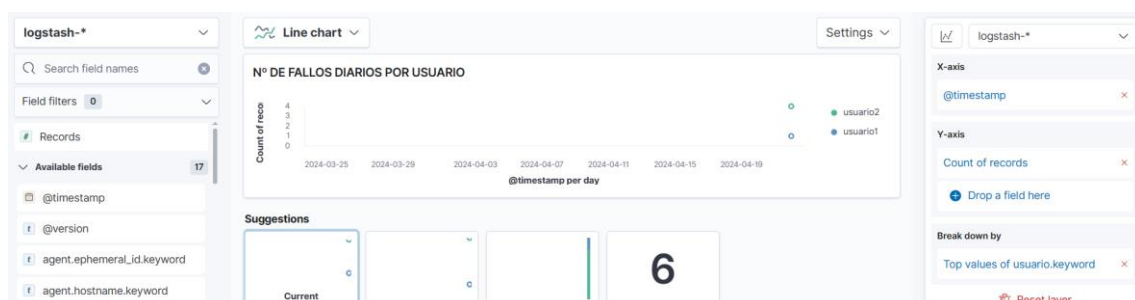


Imagen 10: Creación de una visualización con Lens

Tras crear las visualizaciones con Lens, podemos añadir estas a un dashboard. A continuación, se muestra en la imagen 11 el dashboard con las visualizaciones requeridas.

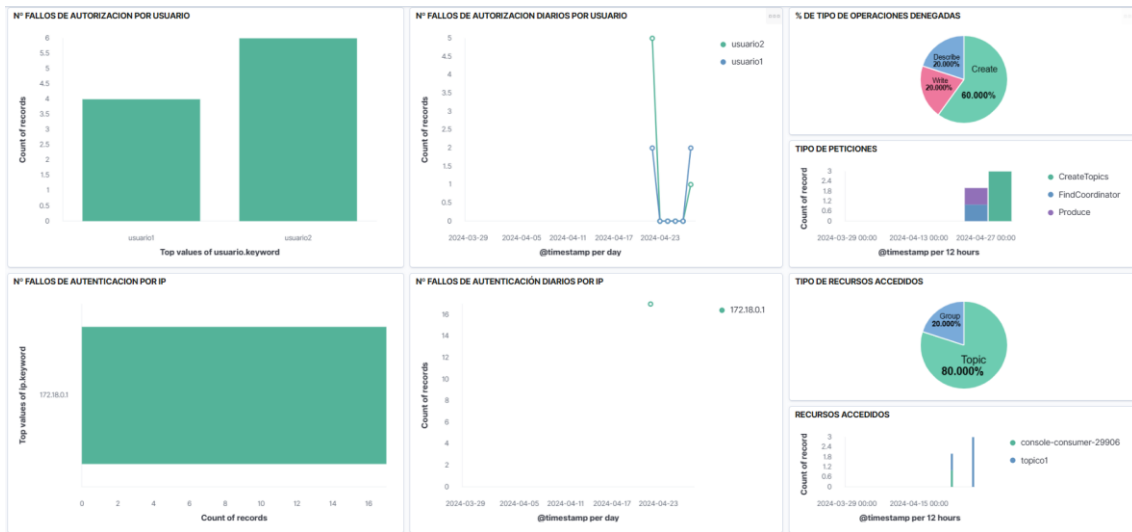


Imagen 11: Dashboard para la autenticación y autorización de Kafka

A continuación, se mostrarán de forma individual las visualizaciones creadas y especificadas en el diseño de la solución:

- Número de fallos de autorización por usuario del sistema




Imagen 12: Número de fallos de autorización por usuario

- Número de fallos de autenticación por ip

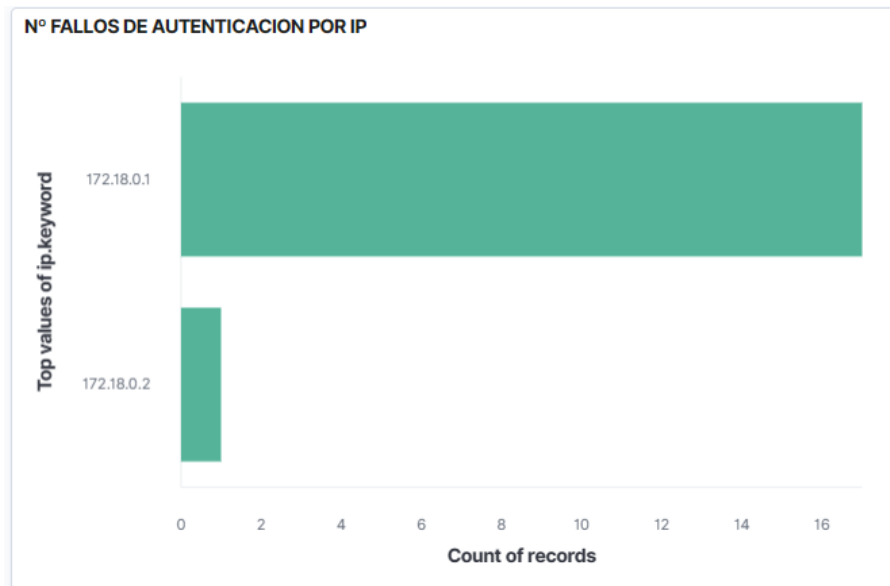


Imagen 13: Número de fallos de autenticación por ip

- Fallos de autorización por usuario en el dominio del tiempo




Imagen 14: Fallos de autorización por usuario en el dominio del tiempo

- Fallos de autenticación por ip en el dominio del tiempo




Imagen 15: Fallos de autenticación por ip en el dominio del tiempo

- Tipos de operaciones de autorización denegadas

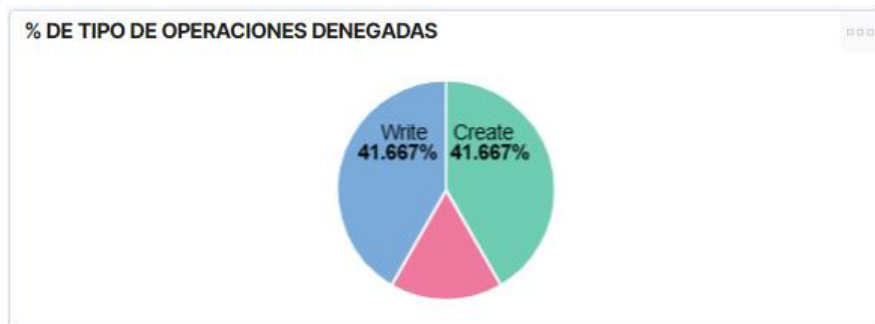


Imagen 16: Tipos de operaciones de autorización denegadas

- Tipos de peticiones de autorización denegadas




Imagen 17: Tipos de peticiones de autorización denegadas

- Tipo de recursos a los que se intenta acceder





Imagen 18: Tipo de recursos a los que se intenta acceder

- Recursos específicos a los que se intenta acceder



Durante el desarrollo de este proyecto, se ha identificado el almacenamiento como la principal limitación debido a la gran cantidad de logs que generan el conjunto de servicios de la plataforma big data. Como el encargado del almacenamiento es Elasticsearch, es en este dónde vemos reflejados los problemas del despliegue local.

4.3.1. Explicación del problema de almacenamiento

Como se ha mencionado previamente, la principal limitación del despliegue local es la capacidad de almacenamiento, ya que los sistemas locales tienen una capacidad de almacenamiento fija, la cual puede ser sobrepasada rápidamente al tratarse de una plataforma big data.

Este problema se ve con facilidad en la gestión de logs, ya que los servicios generan una cantidad masiva de logs diariamente, lo cual unido a la capacidad máxima de almacenamiento acaba resultando en errores críticos como el siguiente:

```
"TOO_MANY_REQUESTS/12/disk usage exceeded flood-stage watermark, index has read-only-allow-delete block"
```

Cuando aparece este problema, Elasticsearch marca los índices como solo lectura para prevenir la pérdida de datos, y esto inutiliza el sistema por completo.

Por ello, concluimos que un sistema de estas características requiere un despliegue distribuido para poder escalar. En caso de que no se pueda llevar a cabo, una solución para eliminar este error sería liberar espacio en disco y posteriormente quitar el bloqueo de solo lectura del índice a través del siguiente comando:

```
curl -X PUT "http://localhost:9200/logstash-kafka-*/_settings" -H
"Content-Type: application/json" -d
"{\"index.blocks.read_only_allow_delete\": null}"
```

Para monitorizar estos errores puede ser útil ver el uso de memoria que está haciendo Elasticsearch con el siguiente comando:

```
curl -X GET
http://localhost:9200/_cat/nodes?v&h=ip,disk.total,disk.used,disk.avail,disk.used_percent
```

O ver la asignación de disco a cada nodo de Elasticsearch:

```
curl -X GET http://localhost:9200/_cat/allocation?v
```

En caso de tener este problema, la salida de este último comando sería similar a la que se muestra a continuación, como se puede ver la asignación de disco está casi llena por el problema descrito anteriormente:

shards	disk.indices	disk.used	disk.avail	disk.total	disk.percent	host	ip
9	10.9mb	375.8gb	14.1gb	389.9gb	96	172.19.0.8	172.19.0.8

Por lo tanto, para solucionar este problema podríamos eliminar el contenedor y volumen periódicamente, aumentar la asignación de disco destinada a Elasticsearch o aplicar políticas ILM (Index Lifecycle Management) [17], que permiten mover a almacenamientos

menos costosos o eliminar colecciones de logs cuando lleguen a una determinada capacidad o según su antigüedad.

5. Diseño de la solución en la nube

Para solucionar los problemas previamente descritos, se despliega el sistema de gestión de logs en la nube, más específicamente en la nube de Google, Google Cloud, ya que nos permite usar la prueba gratuita.

5.1. Docker

Para llevar a cabo el despliegue en la nube vamos a utilizar Docker, misma herramienta utilizada para el despliegue en local.

El acceso a la máquina virtual se realizó mediante claves SSH generadas con el siguiente comando y añadidas al fichero “/.ssh/authorized_keys” en la máquina virtual.

```
ssh-keygen -t rsa -b 2048 -C "jesussaiz@gmail.com"
```

La solución se implementó desplegando los contenedores en una máquina virtual (VM) de Google Cloud. En esta máquina virtual, se instaló el repositorio de Docker, Docker y Docker Compose, posteriormente se copiaron los ficheros de la máquina local a la máquina virtual con el siguiente comando:

```
scp logstash.yml jesus@34.175.10.224:/home/jesus/
```

Y finalmente se ejecutó el fichero de despliegue docker-compose. A continuación, se muestran únicamente los contenedores que han sufrido modificaciones respecto a la versión del despliegue local, con los cambios subrayados en amarillo:

```
filebeat:
  image: docker.elastic.co/beats/filebeat:7.9.3
  user: root
  volumes:
    - /var/lib/docker/containers:/var/lib/docker/containers:ro
    - /var/run/docker.sock:/var/run/docker.sock:ro
    # Archivo de configuración
    - /home/jesus/filebeat.yml:/usr/share/filebeat/filebeat.yml
    # Volumen con los logs de Kafka
    - kafka_logs:/usr/share/filebeat/kafka_logs
  networks:
    - storm
  depends_on:
    - kafka
    - zookeeper
    - cassandra
    - elasticsearch
    - logstash
  command: filebeat -e -strict.perms=false
```

```

logstash:
  image: docker.elastic.co/logstash/logstash:7.9.3
  volumes:
    # Ficheros de configuracion de Logstash
    - /home/jesus/logstash_config:/usr/share/logstash/config
    - /home/jesus/logstash_pipeline:/usr/share/logstash/pipeline
  ports:
    - "5044:5044"
  depends_on:
    - elasticsearch
  networks:
    - storm

```

```

kafka:
  image: wurstmeister/kafka
  container_name: kafka
  ports:
    - "9092:9092"
  environment:
    HOSTNAME: kafka
    HOSTNAME_COMMAND: "docker info | grep 'Node Address: ' | cut -d' '
-f 5"
    KAFKA_ZOOKEEPER_CONNECT: zookeeper:2181
    # modificacion para configurar la autenticacion y autorizacion
    KAFKA_ADVERTISED_LISTENERS: SASL_PLAINTEXT://34.175.107.208:9092
    KAFKA_LISTENERS: SASL_PLAINTEXT://:9092
    KAFKA_INTER_BROKER_LISTENER_NAME: SASL_PLAINTEXT
    KAFKA_AUTHORIZER_CLASS_NAME:
kafka.security.authorizer.AclAuthorizer
    KAFKA_SUPER_USERS: User:admin;User:admin2
    KAFKA_SASL_MECHANISM_INTER_BROKER_PROTOCOL: PLAIN
    KAFKA_SASL_ENABLED_MECHANISMS: PLAIN
    KAFKA_OPTS: "-Djava.security.auth.login.config=/jaas.conf"
  volumes:
    - /var/run/docker.sock:/var/run/docker.sock
    - kafka_logs:/opt/kafka/logs
    - /home/jesus/jaas.conf:/jaas.conf
    - /home/jesus/client.properties:/client.properties
    - /home/jesus/admin.properties:/admin.properties
    - /home/jesus/producer.properties:/producer.properties
    - /home/jesus/consumer.properties:/consumer.properties
  networks:
    - storm

```

Cabe destacar que es imprescindible exponer externamente los puertos a través de reglas en el firewall de Google Cloud para poder acceder a Kibana y los demás contenedores. Para ello se utiliza el siguiente comando. En este caso se expone el puerto para acceder a la

interfaz web de Kibana, pero también es necesario para Kafka, de forma que podamos definir ACLs, escribir, leer tópicos, etc.

```
gcloud compute firewall-rules create allow-kibana-5601 --allow tcp:5601 --
source-ranges 0.0.0.0/0 --target-tags http-server
```

Para comprobar el correcto funcionamiento del sistema vamos a generar logs de autenticación y autorización. Creo las ACLs de Kafka con los siguientes comandos:

```
docker exec -it kafka kafka-acls.sh --bootstrap-server 34.175.107.208:9092
--command-config /admin.properties --add --allow-principal User:usuario1 -
-operation Write --topic topico1
```

```
docker exec -it kafka kafka-acls.sh --bootstrap-server 34.175.107.208:9092
--command-config /admin.properties --add --allow-principal User:usuario2 -
-operation Read --group '*' --topic topico1
```

Ahora ejecutamos los siguientes comandos para generar logs:

```
docker exec -it kafka kafka-console-producer.sh --broker-list
34.175.107.208:9092 --topic topico1 --producer.config /consumer.properties
```

```
docker exec -it kafka kafka-console-consumer.sh --bootstrap-server
34.175.107.208:9092 --topic topico1 --from-beginning --consumer.config
/producer.properties
```

Se muestra en la imagen 21 el menú discover de Kibana, el servicio está situado en la URL <http://34.175.107.208:5601/>, con 34.175.107.208 como ip pública de la máquina virtual. Se puede ver en la imagen 21 que los logs generados han llegado a Kibana, siguiendo el mismo flujo que en el despliegue local.

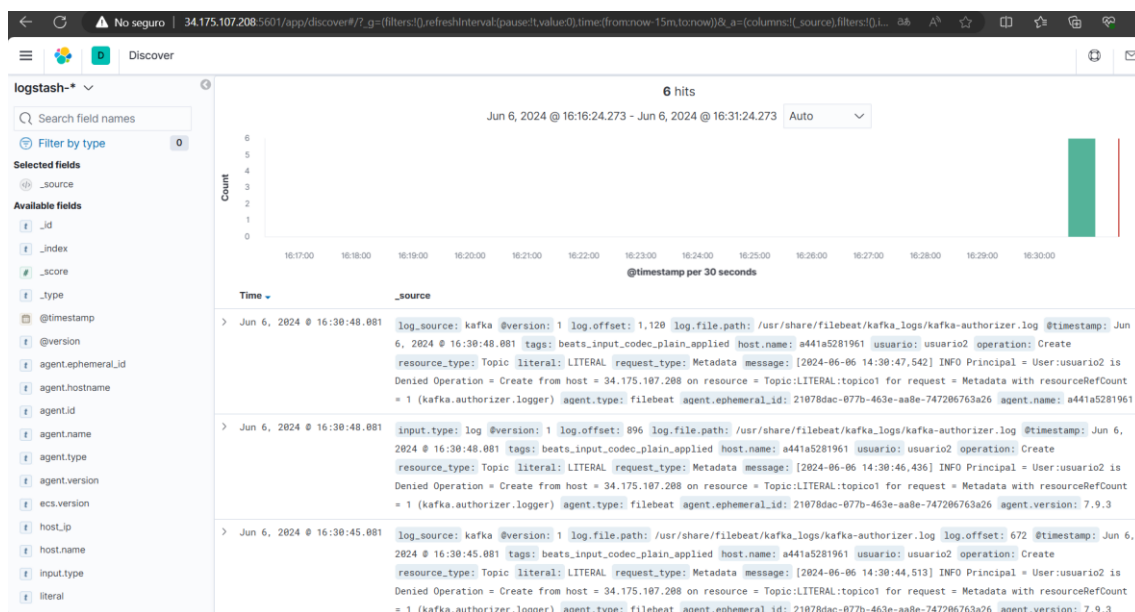


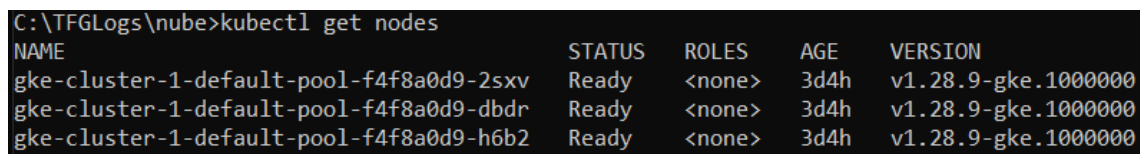
Imagen 21: Menú discover de Kibana desplegado en la nube

5.2. Kubernetes

También se configuró la infraestructura en un entorno Kubernetes, una plataforma de orquestación de contenedores que ofrece ventajas significativas sobre Docker. Kubernetes proporciona capacidades avanzadas como autoescalado, balanceo de carga, y recuperación automática.

Para llevar a cabo el despliegue se utilizó la herramienta Helm. Helm es un gestor de paquetes para Kubernetes que permite desplegar contenedores utilizando charts. Los charts son plantillas predefinidas con anotaciones sobre las que se definen los valores de configuración necesarios para desplegar las aplicaciones en un clúster.

Automáticamente, al crear un clúster, se crea con 3 nodos, esta cantidad no se podrá aumentar al usar la prueba gratuita de Google Cloud.



```
C:\TFGLogs\nube>kubectl get nodes
```

NAME	STATUS	ROLES	AGE	VERSION
gke-cluster-1-default-pool-f4f8a0d9-2sxv	Ready	<none>	3d4h	v1.28.9-gke.1000000
gke-cluster-1-default-pool-f4f8a0d9-dbdr	Ready	<none>	3d4h	v1.28.9-gke.1000000
gke-cluster-1-default-pool-f4f8a0d9-h6b2	Ready	<none>	3d4h	v1.28.9-gke.1000000

Imagen 22: Nodos por defecto de Kubernetes

5.2.1. Zookeeper

Zookeeper es necesario para el funcionamiento de Kafka. Para su despliegue se utiliza el chart oficial de Elastic [22], con configuración por defecto, simplemente ejecutando el siguiente comando:

```
helm install zookeeper bitnami/zookeeper --set replicaCount=1
```

5.2.2. Elasticsearch

Para llevar a cabo el despliegue de Elasticsearch es necesario utilizar un clúster estándar de Google Cloud, es decir, un clúster sin autopilot para la optimización. Esto se debe a que Elasticsearch exige permisos para ejecutar el comando `sysctl`, y esto no es permitido por autopilot.

El despliegue de Elasticsearch se ha realizado utilizando el chart oficial de Elasticsearch proporcionado por Elastic [20]. A continuación, se muestra el fichero de despliegue de Elasticsearch.

```

replicas: 1
minimumMasterNodes: 1
esJavaOpts: "-Xmx512m -Xms512m"
resources:
  requests:
    cpu: "250m"
    memory: "1Gi"
  limits:
    cpu: "500m"
    memory: "1Gi"
volumeClaimTemplate:
  accessModes: [ "ReadWriteOnce" ]
  resources:
    requests:
      storage: 2Gi

```

Con la configuración proporcionada, Elasticsearch se despliega con las configuraciones de seguridad por defecto. Esto significa que, de forma predeterminada, Elasticsearch está configurado para usar autenticación y autorización, así como encriptación de datos utilizando TLS/SSL.

Las anotaciones del chart empleado tienen el siguiente significado:

- **replicas:** Define el número de réplicas del pod de Elasticsearch. En este caso, se ha configurado una sola réplica.
- **minimumMasterNodes:** Define el número mínimo de nodos maestros necesarios para formar un clúster maestro. En este caso, se ha configurado con un valor de 1.
- **esJavaOpts:** Especifica las opciones de JVM para Elasticsearch, incluyendo el tamaño máximo y mínimo de la memoria heap (memoria donde se almacenan los objetos Java).
- **resources:** Define las solicitudes y límites de recursos para el pod de Elasticsearch. Las solicitudes son los recursos garantizados que Kubernetes reservará para el pod, mientras que los límites son el uso máximo permitido.
- **volumeClaimTemplate:** Define un PersistentVolumeClaim (PVC) para el almacenamiento persistente de los datos de Elasticsearch. Este PVC solicita 2Gi de almacenamiento y permite acceso de lectura y escritura.

5.2.3. Kibana

Para desplegar Kibana se ha utilizado el chart oficial de Kibana proporcionado por Elastic [21]. A continuación, se muestra el fichero de despliegue de Kibana, en amarillo se encuentran subrayadas las principales modificaciones realizadas al chart por defecto.

```
elasticsearchHosts: "https://elasticsearch-master:9200"
replicas: 1
extraEnvs:
  - name: "NODE_OPTIONS"
    value: "--max-old-space-size=1800"
image: "docker.elastic.co/kibana/kibana"
imageTag: "8.5.1"
imagePullPolicy: "IfNotPresent"
resources:
  requests:
    cpu: "250m"
    memory: "2Gi"
  limits:
    cpu: "500m"
    memory: "4Gi"
protocol: http
serverHost: "0.0.0.0"
server.publicBaseUrl: "http://35.205.180.18:5601"
healthCheckPath: "/app/kibana"
podSecurityContext:
  fsGroup: 1000
securityContext:
  capabilities:
    drop:
      - ALL
  runAsNonRoot: true
  runAsUser: 1000
serviceAccount: ""
automountToken: false
httpPort: 5601
extraVolumes: []
extraVolumeMounts: []
extraContainers: []
extraInitContainers: []
updateStrategy:
  type: "Recreate"
service:
  type: LoadBalancer
  loadBalancerIP: ""
  port: 5601
  nodePort: ""
  labels: {}
  annotations: {}
  loadBalancerSourceRanges: []
```

```

ingress:
  enabled: false
  className: "nginx"
  pathType: ImplementationSpecific
  annotations: {}
  hosts:
    - host: kibana-example.local
      paths:
        - path: /
  readinessProbe:
    failureThreshold: 3
    initialDelaySeconds: 10
    periodSeconds: 10
    successThreshold: 3
    timeoutSeconds: 5
  imagePullSecrets: []
  nodeSelector: {}
  tolerations: []
  affinity: {}
  nameOverride: ""
  fullnameOverride: ""
  lifecycle: {}

```

Por defecto, Kibana se despliega con las características de seguridad habilitadas [23]. Esto incluye autenticación de usuarios y protección de las comunicaciones mediante TLS/SSL.

Para acceder con el super usuario “elastic” creado automáticamente por Elasticsearch, podemos obtener sus credenciales con los dos siguientes comandos. El primero sirve para obtener la contraseña en base-64 y el segundo para decodificarla en una powershell.

```

kubectl get secrets elasticsearch-master-credentials -o
jsonpath='{.data.password}'

```

```

[System.Text.Encoding]::UTF8.GetString([System.Convert]::FromBase64String(
    "QzFPbUVuaGhEWHVidDZvWA=="))

```

Con el despliegue realizado ya se puede acceder a Kibana a través de la ip y puerto donde está localizado el servicio.

5.2.4. Filebeat

En el despliegue local con Docker solo utilizábamos una instancia de Filebeat que, como dijimos anteriormente, se utilizaba para dar un contexto más realista y poder utilizar un menú de Kibana.

Ahora, para recolectar logs de múltiples servicios en diferentes nodos de un clúster de Kubernetes, se despliega Filebeat como un DaemonSet, esto garantiza que haya una copia de Filebeat corriendo en cada nodo del clúster.

Esta solución es mucho más ligera a nivel de recursos que desplegar un Logstash en cada nodo, y así, Filebeat recogerá los logs de cada nodo y los enviará a un único Logstash centralizado.

Solo se ha llevado a cabo el despliegue de Kibana y Elasticsearch, quedará como desarrollo futuro el despliegue de Filebeat, Logstash y los servicios de la plataforma big data.

6. Conclusiones y líneas de trabajo futuras

Este trabajo, centrado en la gestión de logs en una plataforma big data utilizando el stack ELK, demuestra cómo es posible construir una solución eficiente y escalable para controlar la calidad y seguridad de los datos generados por diferentes servicios.

Empleando herramientas como Elasticsearch, Logstash y Kibana, se ha desarrollado una plataforma que permite la recolección, procesamiento, almacenamiento y visualización de logs. Además, se ha implementado de forma local y, tras explicar los problemas encontrados, se ha movido la plataforma a la nube de Google Cloud. El despliegue en la nube se podía hacer de varias formas, con Docker o Kubernetes, primero se utilizó Docker para conseguir un despliegue más sencillo y, posteriormente, se empezó el despliegue en Kubernetes para observar las diferencias respecto a las implementaciones anteriores.

A lo largo de este proyecto, creo que he adquirido bastante conocimiento en una variedad de tecnologías clave para la gestión y análisis de logs en arquitecturas big data. Desde la configuración y despliegue de contenedores en local con Docker hasta la implementación de soluciones más complejas en la nube con Docker o Kubernetes utilizando Helm, además de profundizar en el uso de bases de datos NoSQL como Elasticsearch y diseñar cuadros de mando tan demandados hoy en día.

Cada etapa ha requerido muchas horas de investigación, solución de errores y la aplicación de conceptos avanzados de administración de sistemas. Este proceso considero que ha enriquecido mi formación técnica en conceptos prácticamente nuevos, que no había tratado a lo largo de la carrera, y creo que me serán muy útiles en el futuro.

Los ficheros de configuración utilizados durante el proyecto se encuentran accesibles públicamente en GitHub [24].

A partir del estado actual del proyecto, se pueden destacar varias líneas de trabajo a futuro:

- **Finalización del despliegue distribuido con Kubernetes:** Actualmente se ha desplegado Kibana y Elasticsearch en Kubernetes. Sería interesante a futuro desplegar al menos una instancia de Kafka por nodo, con su demonio de Filebeat correspondiente encargado de enviar los logs a un único Logstash centralizado. Este Logstash se acoplaría al Elasticsearch y Kibana ya desplegados.
- **Ampliación de los servicios monitorizados:** En este proyecto se ha recogido los logs de múltiples servicios, sin embargo, solo se ha realizado una monitorización detallada de los logs de autenticación y autorización de Kafka. Sería interesante monitorizar logs específicos de los demás servicios de la plataforma big data.

7. Bibliografía

1. Splunk. [Consulta 22 enero]. Enlace: [Qué es Splunk y por qué Debería Importarte - Aprender BIG DATA](#)
2. Graylog. [Consulta 22 enero]. Enlace: [Graylog: gestión de registros líder en la industria para Linux \(linux-console.net\)](#)
3. Fluentd. [Consulta 22 enero]. Enlace: [Fluentd | Open Source Data Collector | Unified Logging Layer](#)
4. Prometheus. [Consulta 23 enero]. Enlace: [Prometheus: Introducción a la Monitorización de Métricas \(aprenderbigdata.com\)](#)
5. Loki. [Consulta 25 enero]. Enlace: [Introducción a Loki | STR Sistemas](#)
6. Datadog. [Consulta 25 enero]. Enlace: [Revisión de Datadog: características clave y precios \(morningdough.com\)](#)
7. Sumo Logic. [Consulta 25 enero]. Enlace: [Introduction to Sumo Logic | Sumo Logic Docs](#)
8. Analíticas de logs. [Consulta: 26 enero 2024]. Enlace: <https://www.elastic.co/es/what-is/log-analytics>
9. Elasticsearch. [Consulta 26 enero 2024]. Enlace: <https://apiumhub.com/es/tech-blog-barcelona/using-elasticsearch-ventajas-libros/>
10. Docker Compose Docs. [Consulta 1 febrero]. Enlace: [Docker Compose overview | Docker Docs](#)
11. Apache Kafka. What is Apache Kafka. [Consulta: 5 febrero 2024]. Enlace: <https://cloud.google.com/learn/what-is-apache-kafka?hl=es>
12. Elasticsearch. What is an Elasticsearch index. [Consulta 6 febrero 2024]. Enlace: <https://www.elastic.co/es/blog/what-is-an-elasticsearch-index>
13. Kibana. Que es Kibana. [Consulta 16 febrero 2024]. Enlace: <https://openwebinars.net/blog/que-es-kibana/>
14. Grok. Plugin filters Grok. [Consulta 16 febrero 2024]. Enlace: <https://www.elastic.co/guide/en/logstash/current/plugins-filters-grok.html>
15. Kappa. [Consulta 20 febrero]. Enlace: [Data processing architectures — Lambda vs Kappa for Big Data. | by Ayush Dixit | Towards Data Engineering | Medium](#)
16. Elasticsearch Mapping. [Consulta 15 marzo]. Enlace: <https://www.elastic.co/guide/en/elasticsearch/reference/current/mapping.html>
17. Elasticsearch. Index Lifecycle. [Consulta 15 marzo]. Enlace: <https://www.elastic.co/guide/en/elasticsearch/reference/current/index-lifecycle-management.html>
18. Kafka. Authorization. [Consulta 22 marzo]. Enlace: <https://developer.ibm.com/tutorials/kafka-authn-authz/>
19. Dintén, R., López Martínez, P. y Zorrilla, M. 2021. Arquitectura de referencia para el diseño y desarrollo de aplicaciones para la Industria 4.0. Revista Iberoamericana de Automática e Informática industrial. 18, 3 (jul. 2021), 300–311. Enlace: <https://doi.org/10.4995/riai.2021.14532>
20. Elasticsearch Chart. [Consulta 20 mayo]. Enlace: [elasticsearch 8.5.1 · elastic/elastic \(artifacthub.io\)](#)
21. Kibana Chart. [Consulta 20 mayo]. Enlace: [kibana 8.5.1 · elastic/elastic \(artifacthub.io\)](#)
22. Zookeeper Chart. [Consulta 20 mayo]. Enlace: [zookeeper 13.4.0 · bitnami/bitnami \(artifacthub.io\)](#)
23. Kibana Security. [Consulta 21 mayo]. Enlace: [Security settings in Kibana | Kibana Guide \[8.5\] | Elastic](#)
24. TFG. Repositorio Github. Enlace: [jesussaizz/TFG \(github.com\)](#)